



## Jeux, Synthèses et Contrôles

---

### Cours 3 : Agnostic setting

---

CARN, Zahra

Thursday 8 October 2020

**Enseignant :**  
Nathanaël FIJALKOW

## Table des matières

<b>1</b>	<b>Inégalités utiles à savoir</b>	<b>2</b>
<b>2</b>	<b>Agnostic Setting</b>	<b>2</b>

# 1 Inégalités utiles à savoir

$$e^x \geq 1 + x, \quad x \in \mathbb{R} \quad (1)$$

$$(1 + x)^a \geq 1 + xa, \quad a, x \geq 0 \quad (2)$$

$$\mathbb{P}(A \cup B) \leq \mathbb{P}(A) + \mathbb{P}(B) \quad (\text{Union Bound})$$

## 2 Agnostic Setting

En français : modèle agnostique

modèle	$X, Y$ $\mathcal{H}$ ensemble de fonctions $X \rightarrow Y$
consistant	On suppose $\exists c \in \mathcal{H}$ et le sample $S = \{(x_i, c(x_i))\}_i$ Objectif : Trouver $h \in \mathcal{H}$ cohérent avec $S$
PAC	On suppose $\mathcal{D}$ sur $X$ , $\exists c \in \mathcal{H}$ et $S \sim \mathcal{D}^m, S = \{(x_i, c(x_i))\}_i$ Objectif : $\mathbb{P}_{S \sim \mathcal{D}^m}(\text{err}_c(h) \leq \epsilon) \geq 1 - \delta$ où $\text{err}_c(h) = \mathbb{P}_{x \sim \mathcal{D}}(h(x) \neq c(x))$
agnostic PAC	On suppose $\mathcal{D}$ sur $X \times Y, S \sim \mathcal{D}^m, S = \{(x_i, y_i)\}_i$ $\text{err}(h) = \mathbb{P}_{(x,y) \sim \mathcal{D}}(h(x) \neq y)$ Objectif : $\mathbb{P}_{S \sim \mathcal{D}^m}(\text{err}(h) - \inf_{h' \in \mathcal{H}} \text{err}(h') \leq \epsilon) \geq 1 - \delta$

On note que  $\inf_{h' \in \mathcal{H}} \text{err}(h')$  le modèle agnostic PAC prend en quelque sorte le rôle de  $c \in \mathcal{H}$  dans le modèle PAC.

**Définition 2.1** (Erreur empirique).

$$h \in \mathcal{H}, \widehat{\text{err}}(h) = \widehat{\text{err}}(h) = \frac{1}{m} \sum_{i=1}^m \mathbb{1}_{h(x_i) \neq y_i}$$

*Note.*  $\mathbb{1}$  est la fonction indice défini par  $\mathbb{1}_A = \begin{cases} 1 & \text{si } A \\ 0 & \text{sinon} \end{cases}$

*Note.*  $\widehat{\phantom{x}}$  est utilisé en probabilités et statistiques pour représenter une valeur **empirique**. C'est à dire une valeur qui est calculée à partir de données.

*Note.*  $\arg \min_{x \in X} f(x)$  retourne une valeur  $x_{\min} \in X$  tel que  $f(x_{\min}) = \min_{x \in X} f(x)$ .

**Définition 2.2** (ERM).  $h$  est une hypothèse ERM (*empirical risk minimisation*) si  $h = \arg \min_{h' \in \mathcal{H}} \widehat{\text{err}}(h')$ .

Un algorithme ERM retourne  $h$  ERM.

$\mathcal{H}$  est apprenable au sens agnostic PAC s'il existe un algo :

$$\forall \epsilon, \forall S, \forall \mathcal{D} \text{ sur } X \times Y, \exists M \in \mathbb{N}, \forall m \geq M, \quad \mathbb{P}_{S \sim \mathcal{D}^m}(\text{err}(h) - \inf_{h' \in \mathcal{H}} \text{err}(h') \leq \epsilon) \geq 1 - \delta \quad (3)$$

**Théorème 2.1.**  $\mathcal{H}$  est apprenable au sens agnostic PAC si et seulement si  $\mathcal{H}$  a VC dimension ( $VCdim$ ) finie.

Cette théorème sera prouvé au cours 4.

**Définition 2.3** (UCP). Propriété de convergence uniforme (*uniform convergence property*) avec un  $\epsilon$  fixé

$$\forall h \in \mathcal{H}, |\text{err}(h) - \widehat{\text{err}}(h)| \leq \frac{\epsilon}{2} \text{ avec } \text{err}(h) = \mathbb{P}_{(x,y) \in \mathcal{D}}(h(x) \neq y)$$

Cette définition permet de simplifier l'objectif de agnostic PAC.

**Lemme 2.2.** On note  $h_{ERM}$  une hypothèse ERM tel que  $\widehat{\text{err}}(h_{ERM}) = \min_{h \in \mathcal{H}} \widehat{\text{err}}(h)$   
Si UCP est vrai (pour  $\epsilon$  fixé), alors l'algorithme ERM satisfait

$$\text{err}(h_{ERM}) - \inf_{h \in \mathcal{H}} \text{err}(h) \leq \epsilon$$

*Démonstration.* Notons  $\text{err}(h_{OPT}) = \inf_{h \in \mathcal{H}} \text{err}(h) \Leftrightarrow h_{OPT} = \arg \inf_{h \in \mathcal{H}} \text{err}(h)$

Objectif : Montrer que  $\text{err}(h_{ERM}) - \text{err}(h_{OPT}) \leq \epsilon$ .

On a

$$\begin{aligned} \text{err}(h_{ERM}) - \text{err}(h_{OPT}) &= \text{err}(h_{ERM}) - \widehat{\text{err}}(h_{ERM}) + \widehat{\text{err}}(h_{ERM}) - \text{err}(h_{OPT}) \\ &\leq \frac{\epsilon}{2} \text{ UCP} \quad \leq \widehat{\text{err}}(h_{OPT}) \text{ par définition} \\ &\leq \frac{\epsilon}{2} + \widehat{\text{err}}(h_{OPT}) - \text{err}(h_{OPT}) \\ &\leq \frac{\epsilon}{2} \text{ UCP} \\ &\leq \epsilon \end{aligned}$$

□

$$X, Y = 0, 1, S \subseteq X$$

$\mathcal{H}$  ensemble de fonctions  $X \rightarrow 0, 1$  correspond à un ensemble de sous-ensembles de  $X$ .

**Définition 2.4.**  $S$  est *shattered* ("explosé" en français) par  $\mathcal{H}$  si

$$\forall P \subseteq S, \exists h \in \mathcal{H}, \forall x \in S, h(x) = 1 \Leftrightarrow x \in P$$

$$\text{Exemple. } X = \mathbb{R}^n, \mathcal{H}_n = \{f | \mathbb{R}^n \rightarrow \{0, 1\} : f(\vec{x}) = \begin{cases} 1 & \text{si } \vec{x} \cdot \vec{a} \geq 0 \\ 0 & \text{sinon} \end{cases}\}$$

avec  $\vec{a} \in \mathbb{R}^n, b \in \mathbb{R}$

$\mathcal{H}_2$  explose  $S := \{(x, y), (x', y')\}$ , avec  $(x, y), (x', y') \in \mathbb{R}^2$ . Une visualisation d'un exemple est donnée dans la figure 1.

$\mathcal{H}_2$  explose  $S := 3$  points non-alignés du plan.

$\mathcal{H}_2$  n'explose pas  $S := 4$  points quelconques du plan.

**Définition 2.5.**  $\text{VCdim}(\mathcal{H}) = \max\{|S| : S \text{ explosé par } \mathcal{H}\}$

*Exemple* ( $\mathcal{H}_2$ ).  $\text{VCdim}(\mathcal{H}_2) = 3$  car  $\exists S, |S| = 3$  explosé et  $\forall S, |S| \geq 4$  non explosé

*Exemple* ( $\text{VCdim}(\mathcal{H}) = \infty$ ).  $X = \mathbb{N}, \mathcal{H}$  toutes les fonctions




FIGURE 1 – Visualisation d'une explosion par  $\mathcal{H}_2$

*Exemple ( $\mathcal{H}_n$ ).  $\text{VCdim}(\mathcal{H}_n) = n + 1$*

*Une présentation au sujet aura lieu dans quelques semaines.*

**Définition 2.6** (Fonction de croissance).

$$S \subseteq X, h \in \mathcal{H}, h : X \rightarrow \{0, 1\}, h|_S : S \rightarrow \{0, 1\}$$

$$\Pi_{\mathcal{H}} : \mathbb{N} \rightarrow \mathbb{N} \quad m \rightarrow \max_{|S|=m, S \subseteq X} |\{h|_S : h \in \mathcal{H}\}| \quad (4)$$

*Exemple.* Si  $\text{VCdim}(\mathcal{H}) = d$  que vaut  $\Pi_{\mathcal{H}}(d)$  ?  $2^d$

Que vaut  $\Pi_{\mathcal{H}}(d-1)$  ?  $2^m$ , pour  $m \leq d$

Que vaut  $\Pi_{\mathcal{H}}(d+1)$  ?  $< 2^{d+1}$

*Remarque.*  $S$  explosé par  $\mathcal{H} \Leftrightarrow |\{h|_S : h \in \mathcal{H}\}| = 2^d$

**Lemme 2.3** (Sauer). Si  $\text{VCdim}(\mathcal{H}) = d$  alors

$$\Pi_{\mathcal{H}}(m) \leq \binom{m}{0} + \binom{m}{1} + \dots + \binom{m}{d} = \sum_{i=0}^d \binom{m}{i} \leq \left(\frac{em}{d}\right)^d = O(m^d)$$

Les instances de la forme  $X$  infini,  $\mathcal{H}$  toutes les fonctions  $X \rightarrow \{0, 1\}$  sont impossibles à apprendre.

*Détails à venir*