

# Cours 2 - PAC : Probably Approximately Correct

Notes par Adrien Maurin

**Définition du problème** Soient  $X$  un ensemble de données (« data points ») et  $Y$  (équivalent à  $\{0, 1\}$ ) un ensemble de labels. Étant donné un couple  $S = \{(x_0, y_0), \dots, (x_m, y_m)\}$ , l'objectif est de trouver  $h : X \rightarrow Y$  avec  $h \in \mathcal{H}$  tel que  $h$  trouve au mieux  $S$ .

**Définition 1** (Consistency model). *La fonction  $h$  du problème défini précédemment vérifie la condition suivante :  $\forall i \in [1, m], h(x_i) = y_i$ .*

## Remarque

1. La fonction n'assure pas la généralité.
2. La fonction ne prend pas en compte le bruit.

**Définition 2** (PAC model). *Ce modèle repose sur l'hypothèse suivante : on suppose que les données sont générées par une distribution  $\mathcal{D}$  inconnue tel que :  $\mathcal{D} : X \rightarrow [0, 1]$  et  $\sum_{x \in X} \mathcal{D}(x) = 1$ .*

On va introduire deux paramètres :

- $\epsilon$  : la précision
- $\delta$  : la confiance

**Algorithme d'apprentissage** Un algorithme d'apprentissage fonctionne de la manière suivante :

Input :  $S = \{(x_0, y_0), \dots, (x_m, y_m)\}$

Output :  $h \in \mathcal{H}$ .

**Définition 3** (erreur). *On définit l'erreur d'une fonction (notée  $err$ ) de la manière suivante :*

$$\forall \epsilon > 0, \forall \delta > 0, \forall c \in \mathcal{H} \text{ (objectif)}, \forall \mathcal{D}, \exists M \in \mathbb{N}, \forall m \geq M : \\ err(h) = \mathbb{P}_{x \sim \mathcal{D}}(h(x) \neq c(x))$$

La notation  $x \sim \mathcal{D}$  signifie que l'on tire un élément  $x$  avec la distribution  $\mathcal{D}$ .

**Définition 4** (apprentissage). *Un algorithme apprend au sens PAC la classe  $\mathcal{H}$  si :*

$$\boxed{\mathbb{P}_{x \sim \mathcal{D}^m}(err(h) \leq \epsilon) \geq 1 - \delta} \quad (1)$$

*En des termes plus simples, cela signifie qu'avec une forte probabilité, mon erreur est faible. On rajoute l'adjectif efficacement si  $m = \text{poly}(\frac{1}{\epsilon}; \frac{1}{\delta})$ .*

**Exemple 1 : ensemble de points sur  $\mathbb{R}^2$**




FIGURE 1 – Illustration du problème.

**Description du problème** Soit un plan sur  $\mathbb{R}^2$ . Sur ce plan, on a des symboles  $-$  et des  $+$ . L'objectif est de déterminer le plus grand rectangle tel que les symboles  $+$  sont dans le rectangle. On définit  $R_h$  le plus petit rectangle qui contient les  $+$ . Le rectangle  $R_c$  étant celui qu'on cherche à déterminer.

On cherche à déterminer  $\mathbb{P}_{x \sim \mathcal{D}^m}(\text{err}(h) \leq \epsilon) \geq 1 - \delta$ . Pour cela, on pose :  $\mathbb{P}_{x \sim \mathcal{D}}(E_{\text{gauche}}) = \mathbb{P}_{x \sim \mathcal{D}} = \frac{\epsilon}{4}$ . On fait de même pour  $E_{\text{droite}}$ ,  $E_{\text{bas}}$  et  $E_{\text{haut}}$ . On définit l'évènement  $A$  suivant :

$$A = \{\exists x, y, z, t \in S, x \in E_{\text{bas}} \wedge y \in E_{\text{haut}} \wedge z \in E_{\text{droite}} \wedge t \in E_{\text{gauche}}\}.$$

Si  $A$  est réalisé, alors on a  $\text{err}_c(h) \leq \epsilon$ . En effet :

$$\text{err}_c(h) = \mathbb{P}_{x \sim \mathcal{D}}(h(x) \neq c(x)) = \mathbb{P}_{x \sim \mathcal{D}}(x \in R_c \setminus R_h) = \mathbb{P}(R_c \setminus R_h)$$

Si l'évènement  $A$  est réalisé, on obtient  $R_c \setminus R_h \subseteq E_{\text{gauche}} \cup E_{\text{droite}} \cup E_{\text{bas}} \cup E_{\text{haut}}$ . On a alors l'inégalité suivante :

$$\mathbb{P}(R_c \setminus R_h) \leq \mathbb{P}(E_{\text{gauche}} \cup E_{\text{droite}} \cup E_{\text{bas}} \cup E_{\text{haut}}) \leq \sum \mathbb{P}(E_i) = \epsilon$$

On a le résultat suivant :  $\mathbb{P}(\forall x \in S, x \notin E_{\text{bas}}) = (1 - \frac{\epsilon}{4})^m$ . On en déduit donc par le complémentaire que :

$$\mathbb{P}(\exists x \in S, x \in E_{\text{bas}}) = 1 - (1 - \frac{\epsilon}{4})^m \leq 1 - e^{-\frac{m\epsilon}{4}}$$

En revenant à l'évènement  $A$ , on obtient :  $\mathbb{P} \geq 1 - 4e^{-\frac{m\epsilon}{4}}$ .

$$\mathbb{P}(A^C) = \mathbb{P}(\forall x \in S, x \notin E_{\text{bas}} \cup \dots \cup x \notin E_{\text{gauche}}) \leq \sum \mathbb{P}(\forall x \in S, x \notin E_i) \leq 4e^{-\frac{m\epsilon}{4}}$$

On en déduit le résultat :  $\mathbb{P}(A) \geq 1 - 4e^{-\frac{m\epsilon}{4}}$ . En combinant ce résultat avec l'équation (1), il faut choisir  $\delta$  tel que  $\delta \leq 4e^{-\frac{m\epsilon}{4}}$ . Cette inégalité est vraie si  $m \geq -\frac{4}{\epsilon} \ln(\frac{\delta}{4})$ .

## Exemple 2 : formules booléennes conjonctives

Soient  $X = \{0, 1\}^n$ ,  $Y = \{0, 1\}$  et  $\mathcal{H} = \{\phi = \bigwedge_i l_i : l_i = p_i \text{ ou } \neg p_i\}$ .  
Par exemple avec  $n = 4$ ,  $\phi = p_1 \wedge p_3 \wedge \neg p_4$

### Algorithme :

- On commence avec  $\phi = p_1 \wedge \neg p_1 \wedge \dots \wedge p_n \wedge \neg p_n$ .
- Pour chaque  $x \in S$  positif, on enlève les littéraux incompatibles dans  $\phi$ .

### Objectif

L'objectif est de trouver  $m \in \mathbb{N}$  qui vérifie l'équation (1). On définit la fonction erreur par :  $\text{err}(h) = \mathbb{P}_{x \sim \mathcal{D}}(x \models \phi_c \not\models \phi_h) \leq \epsilon$

**Définition 5** (mauvais littéral). *Soit  $l$  un littéral. On dit qu'un littéral est mauvais si  $\mathbb{P}_{x \sim \mathcal{D}}(x \models \phi_c \wedge \phi \not\models l) \geq \frac{\epsilon}{2n}$*

**Propriété 1.** *Si  $\phi_h$  ne contient aucun mauvais littéral, alors  $\text{err}(h) \leq \epsilon$ .*

*Démonstration.*

$$\text{err}(h) = \mathbb{P}_{x \sim \mathcal{D}}(x \models \phi_c \wedge x \not\models \phi_h) \leq \sum_{l \in \phi_h} \mathbb{P}_{x \sim \mathcal{D}}(x \models \phi_c \wedge x \not\models l) \leq \sum_{l \in \phi_h} \frac{\epsilon}{2n} \leq \epsilon$$

□

Calculons ensuite la probabilité suivante :

$$\mathbb{P}_{x \sim \mathcal{D}}(\text{Tous les mauvais littéraux apparaissent dans } S)$$

Soit  $l$  un mauvais littéral. On obtient alors :

$$\mathbb{P}_{x \sim \mathcal{D}}(\forall x \in S, x \models \phi_c \implies x \models l) \leq (1 - \frac{\epsilon}{2n})^m \leq e^{-\frac{\epsilon m}{2n}} \text{ car } 1 + x \leq e^x$$

$$\mathbb{P}_{x \sim \mathcal{D}}(\text{Il existe un mauvais littéral dans } S) \leq \sum_l \mathbb{P}(l \text{ apparaisse dans } S) \leq \sum_l e^{-\frac{\epsilon m}{2n}} \leq 2n \cdot e^{-\frac{\epsilon m}{2n}}$$

En appliquant la définition de l'apprentissage (définition 4), on obtient l'inégalité suivante :

$$\delta \geq 2n \cdot e^{-\frac{\epsilon m}{2n}}$$

Cette inégalité est vraie si  $m \geq \frac{2n}{\epsilon} (\ln(2n) + \ln(\frac{1}{\delta}))$ .

### Conclusion

On a l'erreur qui est bien un polynôme en  $\frac{1}{\epsilon}$ . Cependant, ce n'est pas efficacement apprenable car  $m$  est en  $\ln \frac{1}{\delta}$ .